

UNIVERSITÉ
SORBONNE PARIS NORD

- [Portail](#) >
- [WSAIR2_2526](#) >
- [Groupes](#) >
- [Groupe 3](#) >
- [Wiki](#) >
- [Rendu-TP5](#) >
- [Page principale](#)

- [WSAIR2_2526](#)

Web Sémantique

WSAIR2_2526

Jérôme NOBECOURT

Groupe 3

[Documents et liens](#) | [Forums](#) | [Wiki](#) | [Discussion](#)

Groupe 3

Wiki : Rendu-TP5

- [Retour à la page](#)
- [Editer cette page](#)
- [Historique de cette page](#)

[Page principale](#) | [Dernières modifications](#) | [Liste des pages](#) | [Liste des wikis](#) | [Rechercher](#)

Page principale

Compte-rendu TP5 — RDFa et Web Sémantique : La Compagnie des Glaces

Web Sémantique · WSAIR2_2526 · Université Sorbonne Paris Nord

Table des matières

1. 1. Introduction
1. 2. Choix des vocabulaires et alignement LOD
1. 3. Structure de la page RDFa
1. 4. Triplets RDF produits par personnage
1. 5. Sérialisation Turtle de vérification
1. 6. Requêtes SPARQL sur DBpedia
1. 7. Bonnes pratiques W3C (DWBP)

1. 8. Conclusion

1. Introduction

Ce TP porte sur la création d'une page Web annotée en **RDFa 1.1** représentant des données sémantiques sur les personnages de la série de bande dessinée **La Compagnie des Glaces**. L'objectif est qu'un robot ou un agent automatique puisse « avaler » la page HTML et en extraire des triplets RDF exploitables, sans aucune intervention humaine, selon le principe du Web sémantique.

L'intérêt de RDFa (Resource Description Framework in Attributes) réside précisément dans cette dualité : la page reste un document HTML lisible par un utilisateur humain dans un navigateur, tout en embarquant dans ses attributs une couche de métadonnées structurées conformes au modèle RDF. Un moteur de recherche ou un endpoint SPARQL peut ainsi accéder directement aux données sans nécessiter de document RDF séparé.

Le travail s'articule autour de quatre fichiers principaux :

- `index.html` : la page HTML annotée en RDFa 1.1 (fichier principal à livrer) ;
- `personnages.ttl` : les triplets RDF sérialisés en Turtle, servant de document de vérification ;
- `requetes_sparql.sparql` : cinq requêtes SPARQL testables sur l'endpoint DBpedia ;
- `README.md` : la documentation du projet.

Les six personnages couverts dans la page sont : **Tintin**, **Astérix**, **Lucky Luke**, **Francis Blake** (Blake & Mortimer), **Gaston Lagaffe** et **Corto Maltese** — tous des personnages emblématiques de la bande dessinée franco-belge, reliés au LOD Cloud via leurs URIs DBpedia.

2. Choix des vocabulaires et alignement LOD

2.1 Pourquoi plusieurs vocabulaires ?

Une bonne pratique du Web des données consiste à annoter chaque ressource avec plusieurs vocabulaires complémentaires. Cette stratégie de « typage multiple » garantit l'interopérabilité : une application connaissant uniquement `foaf:Person` pourra toujours exploiter les données, même si elle ignore `schema:Person`. De même, un moteur de recherche implémentant Schema.org pourra enrichir ses résultats sans connaître l'ontologie DBpedia.

2.2 Tableau des vocabulaires utilisés

Les vocabulaires retenus sont les suivants :

Préfixe	URI de base	Vocabulaires LOD utilisés	Usage principal
foaf	http://xmlns.com/foaf/0.1/	Personnes, noms, images (<code>foaf:Person</code> , <code>foaf:name</code> , <code>foaf:depiction</code>)	
schema	http://schema.org/	Entités riches : <code>schema:Person</code> , <code>schema:dateCreated</code> , <code>schema:publisher</code> , <code>schema:isPartOf</code>	
dbo	http://dbpedia.org/ontology/	Ontologie DBpedia : <code>dbo:FictionalCharacter</code> , <code>dbo:creator</code> , <code>dbo:nationality</code> , <code>dbo:series</code>	
dc	http://purl.org/dc/elements/1.1/	Dublin Core : <code>dc:title</code> , <code>dc:description</code> , <code>dc:creator</code> , <code>dc:language</code>	
dcterms	http://purl.org/dc/terms/	Dublin Core Terms étendu (métadonnées de la page)	
owl	http://www.w3.org/2002/07/owl#	<code>owl:sameAs</code> pour l'alignement inter-LOD	
rdfs	http://www.w3.org/2000/01/rdf-schema#	<code>rdfs:label</code> , commentaires	
xsd	http://www.w3.org/2001/XMLSchema#	Types de données littéraux (<code>xsd:gYear</code>)	

2.3 Alignement avec DBpedia via owl:sameAs

Chaque personnage de la page possède un attribut `property="owl:sameAs"` pointant vers sa ressource DBpedia officielle. Cette liaison est fondamentale dans le LOD Cloud : elle permet à n'importe quel agent connaissant l'URI DBpedia du personnage de découvrir automatiquement les données de notre page, et réciproquement. C'est le principe du « traversal sémantique » : un robot suit les liens `owl:sameAs` d'un graphe à l'autre pour enrichir sa connaissance d'une entité.

Par exemple, pour Tintin :

```
<link property="owl:sameAs"
      href="http://dbpedia.org/resource/Tintin_(character)"/>
```

Cette instruction, invisible dans le navigateur, produit le triplet :

```
<http://dbpedia.org/resource/Tintin_(character)> owl:sameAs <http://dbpedia.org/resource/Tintin_(character)>
```

3. Structure de la page RDFa

3.1 Déclaration des namespaces dans l'élément racine

Toute la page RDFa 1.1 repose sur la déclaration des préfixes dans l'attribut `prefix` de l'élément `<html>` :

```
<html lang="fr"
  xmlns="http://www.w3.org/1999/xhtml"
  prefix="
    rdf:      http://www.w3.org/1999/02/22-rdf-syntax-ns#
    rdfs:     http://www.w3.org/2000/01/rdf-schema#
    owl:    http://www.w3.org/2002/07/owl#
    dc:       http://purl.org/dc/elements/1.1/
    dcterms: http://purl.org/dc/terms/
    foaf:     http://xmlns.com/foaf/0.1/
    schema:   http://schema.org/
    dbpedia: http://dbpedia.org/resource/
    dbo:      http://dbpedia.org/ontology/
    xsd:      http://www.w3.org/2001/XMLSchema#
  ">
```

Cette approche, conforme à la spécification RDFa 1.1, évite la nécessité de répéter les URIs complètes dans chaque attribut.

3.2 Métadonnées de la page (Dublin Core)

La page elle-même est décrite comme une ressource RDF grâce à un élément englobant portant un attribut `about` :

```
<div about="http://example.org/bd/page"
  typeof="schema:WebPage foaf:Document"
  property="dc:title"
  content="Personnages de Bande Dessinée – Données Sémantiques RDFa">
```

Cela produit les triplets de niveau page : le document est de type `schema:WebPage` et `foaf:Document`, avec un titre Dublin Core. Les métadonnées sont également déclarées dans le `<head>` via des balises `<meta>` classiques (`DC.title`, `DC.creator`, `DC.subject`, `DC.language`, `DC.date`) pour la compatibilité avec les outils qui ne lisent pas RDFa.

3.3 Structure d'une carte personnage

Chaque personnage est représenté par un élément `<div>` portant les attributs RDFa fondamentaux :

- `about` : l'URI de la ressource (l'URI DBpedia du personnage) ;
- `typeof` : le ou les types RDF de la ressource.

Exemple pour Tintin :

```
<div class="card"
  about="http://dbpedia.org/resource/Tintin_(character)"
  typeof="foaf:Person schema:Person dbo:FictionalCharacter">
```

À l'intérieur de cette carte, chaque information affichée dans le navigateur est annotée avec un attribut `property` (pour les littéraux) ou `rel` (pour les liens vers d'autres ressources). L'attribut `resource` est utilisé quand la valeur est une URI non rendue comme lien visible.

3.4 Exemple complet d'annotation d'un créateur

L'annotation du créateur illustre bien la richesse des relations RDF que l'on peut exprimer :

```
<!--Triplet : tintin dbo:creator hergé-->
<span rel="dbo:creator" resource="http://dbpedia.org/resource/Hergé"></span>
<span rel="schema:creator" resource="http://dbpedia.org/resource/Hergé"></span>
```

Les éléments `<span>` vides (invisibles dans le navigateur) permettent de produire des triplets RDF sans afficher de contenu redondant. Le `rel` indique que la propriété pointe vers une autre ressource (URI), par opposition à `property` qui est réservé aux valeurs littérales.

3.5 Annotation des valeurs typées

Les valeurs dont le type XSD est significatif (ici, l'année de première apparition) utilisent l'attribut `datatype` :

```
<span property="schema:dateCreated"
  datatype="xsd:gYear">1929</span>
```

Cela produit le triplet :

```
<tintin> schema:dateCreated "1929"^^xsd:gYear
```

Le type `xsd:gYear` indique explicitement qu'il s'agit d'une année grégorienne, et non d'une chaîne de caractères ordinaire.

4. Triplets RDF produits par personnage

Pour chaque personnage, la page produit un ensemble de triplets du modèle suivant. Le sujet est toujours l'URI DBpedia du personnage.

4.1 Triplets communs à tous les personnages

```
<URI_personnage>
  a foaf:Person, schema:Person, dbo:FictionalCharacter ;
  foaf:name "Nom"@fr ;
  schema:name "Nom"@fr ;
  schema:alternateName "Surnom"@fr ;
  dc:description "Description..."@fr ;
  schema:description "Description..."@fr ;
  dbo:creator <URI_auteur> ;
  schema:creator <URI_auteur> ;
  schema:dateCreated "AAAA"^^xsd:gYear ;
  foaf:depiction <URL_image> ;
  owl:sameAs <URI_dbpedia> .
```

4.2 Triplets spécifiques par personnage

Triplets spécifiques par personnage

Personnage	Propriétés additionnelles
Tintin	dbo:nationality dbr:Belgium · schema:isPartOf dbr:The_Adventures_of_Tintin · dbo:series dbr:The_Adventures_of_Tintin
Astérix	dbo:nationality dbr:Gaul · schema:publisher dbr:Dargaud · deux créateurs (Goscinny et Uderzo)
Lucky Luke	schema:genre dbr:Western_(genre) · dbo:genre dbr:Western_(genre) · schema:publisher dbr:Dargaud
Francis Blake	schema:publisher dbr:Le_Lombard · dbo:creator dbr:Edgar_P._Jacobs
Gaston Lagaffe	schema:worksFor "Éditions Dupuis" · schema:publisher dbr:Dupuis
Corto Maltese	dbo:nationality dbr:Malta · schema:publisher dbr:Casterman

4.3 Exemple de résultat d'extraction (Tintin)

Un outil comme `rdflib` (Python) ou le validateur RDF du W3C extrait automatiquement les triplets suivants en lisant le HTML :

```
<http://dbpedia.org/resource/Tintin_(character)>
  a foaf:Person, schema:Person, dbo:FictionalCharacter ;
  foaf:name "Tintin" ;
  schema:name "Tintin" ;
  schema:alternateName "Le reporter intrépide" ;
  dbo:creator <http://dbpedia.org/resource/Hergé> ;
  schema:creator <http://dbpedia.org/resource/Hergé> ;
  dbo:nationality <http://dbpedia.org/resource/Belgium> ;
  schema:dateCreated "1929"^^xsd:gYear ;
  schema:isPartOf <http://dbpedia.org/resource/The_Adventures_of_Tintin> ;
  dc:description "Jeune reporter belge accompagné de son chien Milou..." ;
  foaf:depiction <https://...wikimedia.org/.../TintinTibet.jpg> ;
  owl:sameAs <http://dbpedia.org/resource/Tintin_(character)> .
```

5. Sérialisation Turtle de vérification

Le fichier `personnages.ttl` contient la sérialisation Turtle de l'ensemble des triplets que la page RDFa doit produire. Ce fichier sert de référence pour valider que l'extraction automatique donne bien le résultat attendu.

5.1 En-tête et déclaration des préfixes

```
@prefix rdf:      <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .
@prefix rdfs:     <http://www.w3.org/2000/01/rdf-schema#> .
@prefix owl:    <http://www.w3.org/2002/07/owl#> .
@prefix xsd:      <http://www.w3.org/2001/XMLSchema#> .
@prefix foaf:     <http://xmlns.com/foaf/0.1/> .
@prefix dc:       <http://purl.org/dc/elements/1.1/> .
@prefix schema:   <http://schema.org/> .
```

```
@prefix dbo:    <http://dbpedia.org/ontology/> .
@prefix dbr:    <http://dbpedia.org/resource/> .
```

5.2 Méthodes d'extraction et de vérification

Plusieurs méthodes permettent de vérifier que la page `index.html` produit bien les triplets attendus :

****Méthode 1 — Valideur W3C en ligne****

Ouvrir <https://www.w3.org/RDF/Validator/>, coller le contenu HTML, et choisir le format de sortie Turtle ou N-Triples.

****Méthode 2 — Python avec rdflib****

```
from rdflib import ConjunctiveGraph

g = ConjunctiveGraph()
g.parse("index.html", format="rdfa")

for s, p, o in g:
    print(f"{s} → {p} → {o}")

# Export Turtle pour comparaison avec personnages.ttl
print(g.serialize(format="turtle"))
```

****Méthode 3 — Apache Any23 (ligne de commande)****

```
any23 -f turtle index.html
```

****Méthode 4 — Schema.org Validator****

Coller l'URL ou le code HTML dans <https://validator.schema.org/>. Cet outil est particulièrement utile pour vérifier que les propriétés `schema:` sont correctement interprétées par Google.

6. Requêtes SPARQL sur DBpedia

Le fichier `requetes_sparql.sparql` contient cinq requêtes exécutables sur l'endpoint officiel DBpedia (<https://dbpedia.org/sparql>).

6.1 Requête 1 — Personnages avec leurs créateurs (VALUES explicites)

Cette requête récupère les six personnages retenus, leurs noms et leurs créateurs, en interrogeant directement l'endpoint DBpedia :

```
PREFIX dbo:    <http://dbpedia.org/ontology/>
PREFIX dbr:    <http://dbpedia.org/resource/>
PREFIX foaf:    <http://xmlns.com/foaf/0.1/>
PREFIX rdfs:    <http://www.w3.org/2000/01/rdf-schema#>

SELECT DISTINCT ?personnage ?nom ?createur ?nomCreateur
WHERE {
  VALUES ?personnage {
    dbr:Tintin_(character)
    dbr:Asterix
    dbr:Lucky_Luke
    dbr:Corto_Maltese
    dbr:Gaston_Lagaffe
  }
  OPTIONAL { ?personnage foaf:name ?nom FILTER(LANG(?nom) = "en") }
  OPTIONAL {
    ?personnage dbo:creator ?createur .
    ?createur rdfs:label ?nomCreateur
    FILTER(LANG(?nomCreateur) = "fr")
  }
}
ORDER BY ?nom
```

L'utilisation de `VALUES` est une technique recommandée pour interroger un ensemble connu de ressources sans recourir à un filtre sur le type, qui serait moins performant.

6.2 Requête 2 — Personnages fictifs de BD belge

```
PREFIX dbo: <http://dbpedia.org/ontology/>
PREFIX dbr: <http://dbpedia.org/resource/>
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>

SELECT DISTINCT ?char ?label ?abstract
WHERE {
  ?char rdf:type dbo:FictionalCharacter ;
        dbo:creator ?creator .
  ?creator dbo:nationality dbr:Belgium .
  OPTIONAL { ?char rdfs:label ?label FILTER(LANG(?label) = "fr") }
  OPTIONAL { ?char dbo:abstract ?abstract FILTER(LANG(?abstract) = "fr") }
}
LIMIT 20
```

Cette requête démontre la puissance du LOD : elle retrouve tous les personnages fictifs dont le créateur a la nationalité belge, sans qu'il soit nécessaire de les lister explicitement.

6.3 Requête 3 — Éditeurs et leurs personnages

```
SELECT ?editeur ?nomEditeur ?personnage ?nomPersonnage
WHERE {
  VALUES ?editeur { <http://dbpedia.org/resource/Dargaud>
                    <http://dbpedia.org/resource/Dupuis>
                    <http://dbpedia.org/resource/Casterman> }
  ?personnage dbo:publisher ?editeur .
  OPTIONAL { ?editeur rdfs:label ?nomEditeur FILTER(LANG(?nomEditeur) = "fr") }
  OPTIONAL { ?personnage foaf:name ?nomPersonnage FILTER(LANG(?nomPersonnage) = "en") }
}
ORDER BY ?editeur
```

6.4 Requête 4 — Exploration des propriétés de Tintin

```
SELECT ?propriete ?valeur
WHERE {
  <http://dbpedia.org/resource/Tintin_(character)> ?propriete ?valeur .
  FILTER(LANG(?valeur) = "fr" || !isLiteral(?valeur))
}
LIMIT 50
```

Cette requête d'exploration est utile pour découvrir quelles propriétés DBpedia documente pour une ressource donnée, ce qui permet ensuite d'enrichir les annotations RDFa en conséquence.

6.5 Requête 5 — Alignement owl:sameAs inter-LOD

```
PREFIX owl: <http://www.w3.org/2002/07/owl#>

SELECT ?perso ?sameAs
WHERE {
  VALUES ?perso {
    <http://dbpedia.org/resource/Tintin_(character)>
    <http://dbpedia.org/resource/Asterix>
    <http://dbpedia.org/resource/Lucky_Luke>
    <http://dbpedia.org/resource/Corto_Maltese>
    <http://dbpedia.org/resource/Gaston_Lagaffe>
  }
  ?perso owl:sameAs ?sameAs .
}
```

Cette requête illustre la structure du LOD Cloud : chaque ressource DBpedia pointe via owl:sameAs vers ses équivalents sur d'autres jeux de données (Wikidata, Freebase, etc.), formant le tissu de liens qui donne son nom au « Web de données ».

7. Bonnes pratiques W3C (DWBP)

La page RDFa a été conçue en suivant les recommandations du W3C sur les bonnes pratiques pour les données sur le Web (Data on the Web Best Practices, DWBP).

7.1 Utilisation d'URIs stables et déréférencables

Les URIs utilisées comme sujets des triplets ([http://dbpedia.org/resource/Tintin_\(character\)](http://dbpedia.org/resource/Tintin_(character)), etc.) sont des URIs stables maintenues par la communauté DBpedia. Elles sont déréférençables : saisir l'URI dans un navigateur renvoie une page de description de la ressource. Ce principe (Linked Data « 4 stars ») garantit la pérennité des données.

7.2 Typage multiple pour l'interopérabilité

Chaque personnage est typé simultanément comme `foaf:Person`, `schema:Person` et `dbo:FictionalCharacter`. Cette redondance volontaire maximise l'interopérabilité : les agents qui ne connaissent qu'un seul de ces vocabulaires peuvent quand même exploiter les données.

7.3 Balisage des langues sur les littéraux

Tous les littéraux textuels portent un tag de langue : `foaf:name "Tintin"@fr`. Cela permet aux applications multilingues de sélectionner la version appropriée et est exigé par les bonnes pratiques DWBP (principe « Provide data in multiple languages »).

7.4 Typage XSD des valeurs numériques et temporelles

Les dates d'apparition sont annotées avec `datatype="xsd:gYear"` plutôt que laissées comme chaînes de caractères. Cela permet à un endpoint SPARQL d'effectuer des comparaisons arithmétiques (`FILTER(?annee > 1950)`) sans ambiguïté.

7.5 Déclaration des namespaces dans l'élément racine

Tous les préfixes sont déclarés une seule fois dans l'attribut `prefix` de `<html>`, conformément à la spécification RDFa 1.1. Cette approche est préférable à la déclaration répétée de namespaces XML dans chaque élément.

7.6 Métadonnées Dublin Core sur la page elle-même

La page est décrite comme une ressource à part entière, avec des métadonnées Dublin Core (`dc:title`, `dc:creator`, `dc:subject`, `dc:language`, `dc:date`). Cela respecte le principe DWBP « Provide metadata » et permet aux moteurs d'indexation de catégoriser le document.

7.7 Résumé des conformités DWBP

- URIs stables et déréférençables (dbpedia.org/resource/)
- `owl:sameAs` pour l'alignement avec le LOD Cloud
- Typage multiple (`foaf` + `schema` + `dbo`) pour l'interopérabilité
- Tags de langue (`@fr`) sur tous les littéraux textuels
- Types de données XSD (`^xsd:gYear`) sur les valeurs temporelles
- Namespaces déclarés dans `prefix` de `<html>` (RDFa 1.1 natif)
- Métadonnées Dublin Core sur la page elle-même
- `about` et `typeof` conformes RDFa 1.1
- Fichier Turtle de vérification fourni séparément

8. Conclusion

Ce TP a permis de mettre en pratique le principe fondateur du Web sémantique : enrichir des pages HTML ordinaires d'une couche de métadonnées formalisées, lisibles par les machines, sans sacrifier la lisibilité humaine du document.

La technique RDFa se distingue des autres approches d'annotation (Microdata, JSON-LD) par sa capacité à annoter précisément chaque fragment visible du HTML — un nom, un lien, une date — en lui associant un triplet RDF. Contrairement à JSON-LD, qui consigne les métadonnées dans un bloc `<script>` séparé du contenu affiché, RDFa garantit une cohérence absolue entre ce que l'utilisateur voit et ce qu'un robot extrait.

L'utilisation combinée de plusieurs vocabulaires du LOD (FOAF, Schema.org, DBpedia Ontology, Dublin Core) et le recours systématique à `owl:sameAs` pour relier les ressources à DBpedia illustrent concrètement les principes du Linked Open Data. Un robot sémantique parcourant la page peut ainsi, par simple traversée de liens, accéder à l'ensemble des données que DBpedia possède sur chaque personnage, et inversement enrichir le graphe de connaissance global avec les données locales de la page.

Les cinq requêtes SPARQL produites montrent enfin l'exploitation de ces données à l'échelle du LOD Cloud : il devient possible de retrouver tous les personnages fictifs belges, d'explorer les éditeurs de BD, ou de cartographier les liens `owl:sameAs` d'une ressource vers d'autres jeux de données — autant d'opérations impossibles avec un simple document HTML non annoté.

Gestionnaire(s) de WSAIR2_2526 : Jérôme NOBECOURT

Administrateur de Portail : Webmestre

Utilise la plateforme Claroline © 2001 - 2013

modifiée depuis 2013 à aujourd'hui pour ce portail